





30.04.2024 Computer Vision Seminar 23/24






Agenda

- 1. Wizja komputerowa w 2D a 3D
- 2. Reprezentacje danych 3D
- 3. Typy segmentacji
- 4. Segmentacja z użyciem DL





Tensory



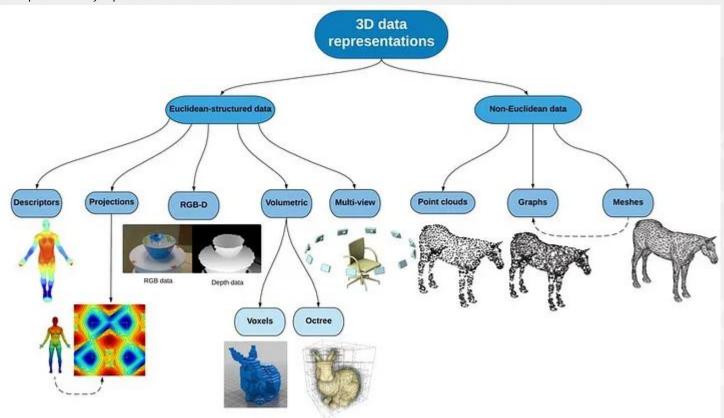
Vector: 1D array

Image: 2D tensor (for each color channel)

Video: 3D tensor (for each color channel)


From Pixels to 3D Shapes: An Overview of 3D Data Representations | by Dedeepya Lekkala | Medium

















LiDAR – light detection and ranging








Lidar - Wikipedia





Depth map

- Zdjęcie/kanał
- Jasność pikseli oznacza głębię (im jaśniej, tym bliżej znajduje się obiekt)



How to represent 3D Data



RGB-D

- Połączenie informacji o kolorze (RGB) z głębią (D)
- Informacja 2,5D
- Prosta, popularna reprezentacja





How to represent 3D Data



Projekcje

- Istnieje bardzo dużo projekcji tego samego obiektu
- Sferyczne/birds-eye
- Strata informacji w wyniku projekcji







Multi-view

- Sposób na szum, niepełną informację, okluzję (occlusion)
- Trudne pytanie: ile potrzeba takich ujeć?



How to represent 3D Data







Woksele (voxels, volumetric picture element)

- Odpowiednik piksela w 3D
- Przedstawienie sceny jako trójwymiarowej tablicy

7,640,640 pixels 5mm nodule = ~3.67 x 10⁻⁵%

 Przechowują informację o tym, co jest w środku bryły (solid modelling)











Siatka (mesh)

- Wykorzystuje wielokąty połączone ze sobą krawędziami
- Zwykle proste wielokąty, np. trójkąty









Chmury punktów

- Zbiór punktów w układzie trójwymiarowym
- Współrzędne X, Y, Z
- Dane zebrane np. przez LiDAR
- Szybkie renderowanie
- Brak struktury (trudne do przetworzenia przez CNN)







Equivalence of Representations



- Thesis:
 - Each fundamental representation has enough expressive power to model the shape of any geometric object
 - o It is possible to perform all geometric operations with any fundamental representation!
- Analogous to Turing-Equivalence:
 - All computers today are turing-equivalent, but we still have many different processors

Computational Differences



- Efficiency
 - o Combinatorial complexity (e.g. O(n log n))
 - o Space/time trade-offs (e.g. z-buffer)
 - o Numerical accuracy/stability (degree of polynomial)
- Simplicity
 - o Ease of acquisition
 - o Hardware acceleration
 - o Software creation and maintenance
- Usability
 - o Designer interface vs. computational engine



Typy segmentacji



<u>Image Segmentation: Deep Learning vs</u> <u>Traditional [Guide]</u>

Semantic Segmentation vs. Instance Segmentation vs. Panoptic Segmentation



(a) Image



(b) Semantic Segmentation



(c) Instance Segmentation




(d) Panoptic Segmentation

V7 Labs



Segmentacja z użyciem głębokich sieci neuronowych

Convolutional encoder-decoder



<u>Image Segmentation: Deep Learning vs</u> <u>Traditional [Guide]</u>

An overview of Semantic Image Segmentation








SemanticKITTI dataset









RangeNet++





Fig. 2: Block diagram of the approach. Each of the arrows corresponds to one of our modules.








SOTA semantic segmentation

3D Semantic Segmentation on Semantic KITTI







Materialy

- Overview of 3D Object Representations
- From Pixels to 3D Shapes: An Overview of 3D Data Representations | by Dedeepya Lekkala | Medium
- How to represent 3D Data
- Image Segmentation: Deep Learning vs Traditional [Guide]
- An Intuitive Introduction to Point Net